Informe 6: Construyendo modelos

Carmen Lebrero Cia

Construcción de modelo de Machine Learning supervisado con datos de expresión génica

En este informe tenemos como objetivo construir un modelo de Machine Learning Supervisado utilizando los datos de Expresión génica transformados. Además utilizaremos la versión filtrada de estos datos por un lado, y la versión con únicamente los genes diferencialmente expresados por otro.

Obtención y procesado de los datos

Instalación y puesta en marcha de los paquetes necesarios

```
if (!requireNamespace("BiocManager", quietly=TRUE))
    install.packages("BiocManager")
BiocManager::install("TCGAbiolinks")
library(TCGAbiolinks)
library(dplyr)
library(SummarizedExperiment)
library(DT)
```

Descarga de los datos y preparación de objetos R

Preprocesado

```
#subconjunto quedándonos con las filas con sumatorio de conteos mayores a 1 y guardado de este cambio e
keep <- rowSums(assay(ExpGenTCGA_KIRC_RawData)) > 1
ExpGenTCGA_KIRC_RawData <- ExpGenTCGA_KIRC_RawData[keep,]
nrow(assay(ExpGenTCGA_KIRC_RawData))</pre>
```

Normalización

```
#Downstream análisis usando datos de expresión génica de muestras de TCGA de IlluminaHiSeq_RNASeqV2 co

ExpGenTCGA_KIRC_Norm <- TCGAanalyze_Normalization(tabDF = ExpGenTCGA_KIRC_RawData, geneInfo = geneInfo
```

Transformación log2

```
ExpGenTCGA_KIRC_Norm_Trans<- log2(ExpGenTCGA_KIRC_Norm+1)</pre>
ExpGenTCGA_KIRC_Norm_Trans[1:10,1:3]
##
            TCGA-B0-5694-01A-11R-1541-07 TCGA-CJ-4637-01A-02R-1325-07
## A1BG
                                 5.209453
                                                               6.475733
## A2M
                                16.117704
                                                              15.538310
## NAT1
                                 6.807355
                                                               8.209453
## NAT2
                                 2.584963
                                                               6.988685
## SERPINA3
                                 8.724514
                                                               9.330917
## AADAC
                                 0.000000
                                                               6.285402
## AAMP
                                12.147523
                                                              12.221285
## AANAT
                                 1.000000
                                                               0.000000
## AARS
                                12.055282
                                                              12.634584
## ABAT
                                 9.459432
                                                               9.894818
##
            TCGA-CZ-4860-01A-01R-1305-07
## A1BG
                                 5.930737
## A2M
                                15.254106
## NAT1
                                 7.707359
## NAT2
                                 3.321928
## SERPINA3
                                10.615630
## AADAC
                                 2.321928
## AAMP
                                13.512000
## AANAT
                                 0.000000
```

Obtención de los objetos de datos filtrados y DEGs

14.873588

8.243174

Filtrado

AARS

ABAT

```
#quantile filter of genes
dim(ExpGenTCGA_KIRC_Norm)
ExpGenTCGA_KIRC_Norm_Filt75 <- TCGAanalyze_Filtering(tabDF = ExpGenTCGA_KIRC_Norm, method = "quantile",
dim(ExpGenTCGA_KIRC_Norm_Filt75)</pre>
```

Pasamos de tener 19586 genes a 4897 genes.

```
#quantile filter of genes
dim(ExpGenTCGA_KIRC_Norm_Trans)
ExpGenTCGA_KIRC_Norm_Trans_Filt75 <- TCGAanalyze_Filtering(tabDF = ExpGenTCGA_KIRC_Norm_Trans, method =
dim(ExpGenTCGA_KIRC_Norm_Trans_Filt75)</pre>
```

Análisis de expresión diferencial

```
ExpGenTCGA_KIRC_SampleName_DeadStatus <- subset(ExpGenTCGA_KIRC_RawData$barcode, ExpGenTCGA_KIRC_RawDat ExpGenTCGA_KIRC_SampleName_AliveStatus <- subset(ExpGenTCGA_KIRC_RawData$barcode, ExpGenTCGA_KIRC_RawData$barcode, ExpGenTCGA_K
```

```
ExpGenTCGA_KIRC_Norm_Trans_Filt75_DEGs <- TCGAanalyze_DEA(mat1 = ExpGenTCGA_KIRC_Norm_Trans_Filt75[,Exp

mat2 = ExpGenTCGA_KIRC_Norm_Trans_Filt75[,ExpGenTCGA_KIRC_SampleName_AliveS'

Cond1type = "Dead",

Cond2type = "Alive",

fdr.cut = 0.10,

logFC.cut = 0.4,

method = "glmLRT")
```

```
dim(ExpGenTCGA_KIRC_Norm_Filt75_DEGs)
```

```
## [1] 238 5
```

Vamos a hacer un subconjunto de nuestro set de Expresión génica con los 238 genes que hemos visto que tienen expresión diferencial tras el análisis.

```
#Obtención de índices de DEGs en ExpGenTCGA_KIRC_Norm_Filt75 (números de fila)

DEGSNames <- rownames(ExpGenTCGA_KIRC_Norm_Filt75_DEGs)

IndexDEGs_in_ExpGenTCGA_KIRC_Norm_Filt75 <- c()

for (i in DEGSNames){
    IndexDEGs_in_ExpGenTCGA_KIRC_Norm_Filt75 <- c(IndexDEGs_in_ExpGenTCGA_KIRC_Norm_Filt75, which(rownames)}

str(IndexDEGs_in_ExpGenTCGA_KIRC_Norm_Filt75)
```

```
ExpGenTCGA_KIRC_Norm_Filt75_238DEG <- ExpGenTCGA_KIRC_Norm_Filt75[IndexDEGs_in_ExpGenTCGA_KIRC_Norm_Filt75_238DEG)
rownames(ExpGenTCGA_KIRC_Norm_Filt75_238DEG)</pre>
```

Subconjunto de toda la matriz ExpGenTCGA KIRC Norm Filt75 de las filas de los DEGs

```
# Subconjunto de toda la matriz ExpGenTCGA_KIRC_Norm_Trans_Filt75 de las filas de los DEGs
```

ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- ExpGenTCGA_KIRC_Norm_Trans_Filt75[IndexDEGs_in_ExpGenTCGA_K
dim(ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG)</pre>

Construcción del modelo

Instalación de paquetes

```
##
## Attaching package: 'keras'
## The following object is masked from 'package:BiocGenerics':
##
## normalize
install_keras()
```

Introducción al aprendizaje supervisado

El aprendizaje supervisado consiste en "mapear" unos datos de entrada a unas etiquetas targets (también conocidas como anotaciones), dados un conjunto de ejemplos anotados por humanos. Casi todas las aplicaciones de Deep Learning actuales pertenecen a esta categoría. Por lo que, necesitaremos unas etiquetas (Labels) para nuestros datos, en nuestro caso tomaremos la variable vital status.

Preparación datos, conjuntos de test y train y etiquetas

Vamos a cambiar el array y vamos a poner las muestras como filas y las filas como muestras. Vamos a realizar la prueba del modelo de Deep Learning con dos tipos de datos:

- ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG_Transposed: Los datos de Expresion Génica de KIRC, normalizados, transformados, con filtrado de genes al 75% y con los 238 genes más diferencialmente expresados. Número de muestras = 606, número de genes = 238.
- ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed: Los datos de Expresion Génica de KIRC, normalizados, transformados y con filtrado de genes al 75%. Número de muestras = 606, número de genes = 4897.

```
ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG_Transposed <- t(ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG)
ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed <- t(ExpGenTCGA_KIRC_Norm_Trans_Filt75)</pre>
```

```
# Creación set train y test para ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG_Transposed

set.seed(231)

ExpGenTCGA_KIRC_Index_Training <- sample(1:nrow(ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG_Transposed), s
```

```
# Creación set train y test para ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed

ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed_Test <- ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed[-ExpG

ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed_Train <- ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed[ExpG

# Obtener etiquetas de cada set para ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG_Transposed

ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed_Test_Labels <- ExpGenTCGA_KIRC_RawData$vital_status[-ExpGe

ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed_Train_Labels <- ExpGenTCGA_KIRC_RawData$vital_status[ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed_Test_Labels_FactorNumb <- as.integer(factor(ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed_Test_Labels_FactorNumb (ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed_Test_Labels_FactorNumb <- as.integer(factor(ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed_Test_Labels_FactorNumb (ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed_Test_Labels_FactorNumb (ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed_Test_Labels_FactorNumb (ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed_Test_Labels_FactorNumb (ExpGenTCGA_KIRC_Norm_Trans_Filt75_Transposed_Train_Labels_FactorNumb (ExpGenTCGA_KIRC_Norm_Trans_Filt
```

ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG_Transposed_Test <- ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG_Transposed_Train <- ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG_Transposed_Train <- ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG_Transposed_Train_

Creación del modelo

Modelo 1


```
# Definición del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG
Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- keras_model_sequential() %>%
    layer_dense(units = 16, activation = "relu", input_shape = c(238)) %>%
    layer_dense(units = 16, activation = "relu") %>%
    layer_dense(units = 1, activation = "sigmoid")
```

summary(Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG)

history <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% fit(ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% fit(ExpGenTCGA_KIRC_Norm

plot(history)

`geom_smooth()` using formula 'y ~ x'



Evaluación del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

```
## loss accuracy
## 0.6201108 0.6721311
```

Buscando el overfitting del modelo

Crear un modelo que se sobreajuste es bastante fácil:

- 1. Añadir capas
- 2. Hacer las capas más grandes
- 3. Entrenar para más iteraciones

Modelo 2

```
# Definición del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG
Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- keras_model_sequential() %>%
  layer_dense(units = 200, activation = "relu", input_shape = c(238)) %>%
  layer_dense(units = 100, activation = "relu") %>%
  layer_dense(units = 50, activation = "relu") %>%
  layer_dense(units = 1, activation = "sigmoid")
```

summary(Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG)

```
## Model: "sequential_1"
## Layer (type) Output Shape Param #
(None, 200)
## dense 6 (Dense)
## dense_5 (Dense)
                     (None, 100)
                                      20100
## dense_4 (Dense)
                    (None, 50)
                                      5050
## dense_3 (Dense) (None, 1)
## Total params: 73,001
## Trainable params: 73,001
## Non-trainable params: 0
```

```
# Compilación del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG


Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% compile(
  optimizer = "rmsprop",
  loss = "binary_crossentropy",
  metrics = c("accuracy")
)
```

${\it\# Entrenamiento\ del\ modelo\ ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG}$

history <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% fit(ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG validation_split = 0.2)

plot(history)

`geom_smooth()` using formula 'y ~ x'



Evaluación del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG


Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

```
## loss accuracy
## 0.6128544 0.6721311
```

Modelo 3

```
# Definición del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG
Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- keras_model_sequential() %>%
layer_dense(units = 400, activation = "relu", input_shape = c(238)) %>%
```

```
layer_dense(units = 200, activation = "relu") %>%
 layer_dense(units = 100, activation = "relu") %>%
 layer_dense(units = 1, activation = "sigmoid")
summary(Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG)
## Model: "sequential_2"
## Layer (type)
                            Output Shape
                                                          Param #
## dense 10 (Dense)
                                (None, 400)
                                                           95600
## dense_9 (Dense)
                                (None, 200)
                                                           80200
## dense_8 (Dense)
                                (None, 100)
                                                           20100
## dense_7 (Dense) (None, 1)
                                                      101
## Total params: 196,001
## Trainable params: 196,001
## Non-trainable params: 0
{\it\# Compilaci\'on del modelo ExpGenTCGA\_KIRC\_Norm\_Trans\_Filt75\_238DEG}
Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% compile(
 optimizer = "rmsprop",
 loss = "binary_crossentropy",
 metrics = c("accuracy")
# Entrenamiento del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG
history <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% fit(ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>%
                                                       validation_split = 0.2)
plot(history)
## `geom_smooth()` using formula 'y ~ x'
```



Evaluación del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

loss accuracy ## 0.5909629 0.6803279


Modelo 4

```
# Definición del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG
Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- keras_model_sequential() %>%
    layer_dense(units = 400, activation = "relu", input_shape = c(238)) %>%
    layer_dense(units = 200, activation = "relu") %>%
    layer_dense(units = 100, activation = "relu") %>%
    layer_dense(units = 1, activation = "sigmoid")
```

summary(Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG)

Model: "sequential_3"

```
## Layer (type)
                   Output Shape
                                            Param #
## -----
## dense_17 (Dense)
                          (None, 400)
## dense 16 (Dense)
                         (None, 200)
                                               80200
## dense_15 (Dense)
                         (None, 100)
                                                20100
## dense_14 (Dense)
                          (None, 100)
                                               10100
## dense_13 (Dense)
                          (None, 100)
                                               10100
## dense_12 (Dense)
                          (None, 100)
                                               10100
## dense_11 (Dense)
             (None, 1)
## Total params: 226,301
## Trainable params: 226,301
## Non-trainable params: 0
## ______
# Compilación del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG
optimizer = "rmsprop",
 loss = "binary_crossentropy",
 metrics = c("accuracy")
# Entrenamiento del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG
history <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% fit(ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>%
                                            validation_split = 0.2)
plot(history)
```



Evaluación del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

loss accuracy ## 0.6019629 0.7049180

Modelo 5

```
# Definición del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG
Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- keras_model_sequential() %>%
    layer_dense(units = 200, activation = "relu", input_shape = c(238)) %>%
    layer_dense(units = 100, activation = "relu") %>%
    layer_dense(units = 50, activation = "relu") %>%
    layer_dense(units = 20, activation = "relu") %>%
    layer_dense(units = 1, activation = "sigmoid")
```

```
summary(Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG)
```


```
## Model: "sequential_4"
## ______
```

```
## dense_22 (Dense)
                                 (None, 200)
## dense_21 (Dense)
                                (None, 100)
                                                             20100
## dense_20 (Dense)
                                (None, 50)
                                                            5050
## dense_19 (Dense)
                                 (None, 20)
                                                            1020
## dense_18 (Dense) (None, 1)
## Total params: 73,991
## Trainable params: 73,991
## Non-trainable params: 0
## _____
{\it\# Compilaci\'on del modelo ExpGenTCGA\_KIRC\_Norm\_Trans\_Filt75\_238DEG}
Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% compile(
 optimizer = "rmsprop",
 loss = "binary_crossentropy",
 metrics = c("accuracy")
# Entrenamiento del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG
history <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% fit(ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>%
                                                         validation_split = 0.2)
plot(history)
```

Output Shape

Param #

Layer (type)



${\it\# Evaluaci\'on del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG}$

Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

loss accuracy ## 0.5889738 0.6721311

Modelo 6


```
# Definición del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- keras_model_sequential() %>%
    layer_dense(units = 200, activation = "relu", input_shape = c(238)) %>%
    layer_dense(units = 100, activation = "relu") %>%
    layer_dense(units = 50, activation = "relu") %>%
    layer_dense(units = 20, activation = "relu") %>%
    layer_dense(units = 10, activation = "relu") %>%
    layer_dense(units = 5, activation = "relu") %>%
    layer_dense(units = 1, activation = "relu") %>%
    layer_dense(units = 1, activation = "sigmoid")
```

summary(Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG)

Model: "sequential_5"

```
Output Shape
## Layer (type)
                                            Param #
## dense_29 (Dense)
                          (None, 200)
## dense_28 (Dense)
                         (None, 100)
                                               20100
## dense_27 (Dense)
                          (None, 50)
                                                5050
## dense_26 (Dense)
                          (None, 20)
                                               1020
## dense_25 (Dense)
                          (None, 10)
                                               210
                          (None, 5)
## dense_24 (Dense)
## dense_23 (Dense)
                   (None, 1)
## Total params: 74,241
## Trainable params: 74,241
## Non-trainable params: 0
## ______
# Compilación del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG
optimizer = "rmsprop",
 loss = "binary_crossentropy",
 metrics = c("accuracy")
# Entrenamiento del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG
history <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% fit(ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>%
                                             validation_split = 0.2)
plot(history)
```



Evaluación del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

loss accuracy ## 0.6335880 0.6721311

Modelo 7

```
# Definición del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- keras_model_sequential() %>%
    layer_dense(units = 500, activation = "relu", input_shape = c(238)) %>%
    layer_dense(units = 300, activation = "relu") %>%
    layer_dense(units = 100, activation = "relu") %>%
    layer_dense(units = 50, activation = "relu") %>%
    layer_dense(units = 1, activation = "sigmoid")


summary(Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG)
```

```
(None, 500)
## dense_34 (Dense)
## dense_33 (Dense)
                                (None, 300)
                                                            150300
## dense_32 (Dense)
                                (None, 100)
                                                            30100
## dense_31 (Dense)
                                 (None, 50)
                                                            5050
## dense_30 (Dense) (None, 1)
## Total params: 305,001
## Trainable params: 305,001
## Non-trainable params: 0
## _____
{\it\# Compilaci\'on del modelo ExpGenTCGA\_KIRC\_Norm\_Trans\_Filt75\_238DEG}
Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% compile(
 optimizer = "rmsprop",
 loss = "binary_crossentropy",
 metrics = c("accuracy")
# Entrenamiento del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG
history <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% fit(ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>%
                                                        validation_split = 0.2)
plot(history)
```

Output Shape

Param #

Layer (type)



Evaluación del modelo ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG <- Model_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG %>% Results_ExpGenTCGA_KIRC_Norm_Trans_Filt75_238DEG

```
## loss accuracy
## 0.6445902 0.6803279
```

tfruns: Track and Visualize Training Runs

Una mejor manera de comparar los entrenamientos es con el paquete tfruns.

- Hace un seguimiento de los hiperparámetros, métricas, resultados y código fuente de cada entrenamiento.
- Compara hiperparámetros y métricas de todos los runs y encuentra el mejor modelo.
- Genera automáticamente informes para visualizar indivualmente los entrenamientos o comparación entre runs.
- No se necesita cambiar el código fuente.

Instalación

```
install.packages("tfruns")
install.packages("tfestimators")
```

Entrenamiento

En las siguientes secciones se describirán las capacidades de tfruns. Nuestro script de entrenamiento script.R entrena un modelo Keras para clasificar pacientes entre vivos y muertos a partir de datos de Expresión génica.

Para entrenar la red con tfruns utiliza la función training_run() para ejecutar el script de R.

```
library(tfestimators)
library(tfruns)
training_run("script.R")
```

Cuando el entrenamiento se haya completado, un resumen de la ejecución aparecerá en pantalla si estás en una sesión interactiva de R.

Enlaces de interés

 $https://riuma.uma.es/xmlui/bitstream/handle/10630/13942/103060005.pdf; jsessionid=CBBC364B3A641B87C959E0E5C42\\ sequence=1 https://tensorflow.rstudio.com/tools/tfruns/overview/ https://tensorflow.rstudio.com/tools/tensorboard/tensorboard/$